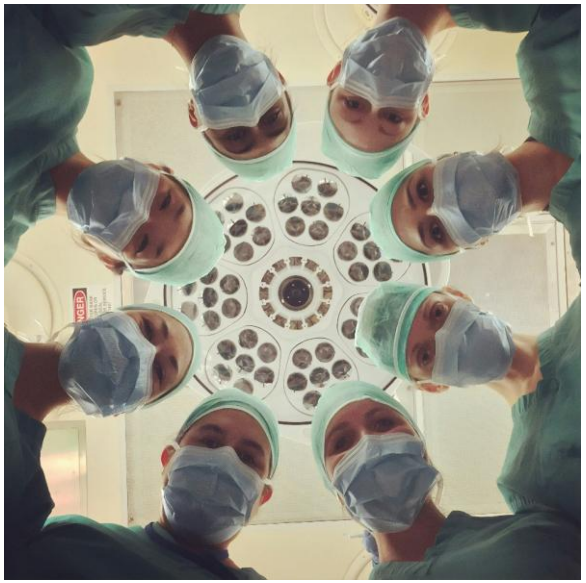
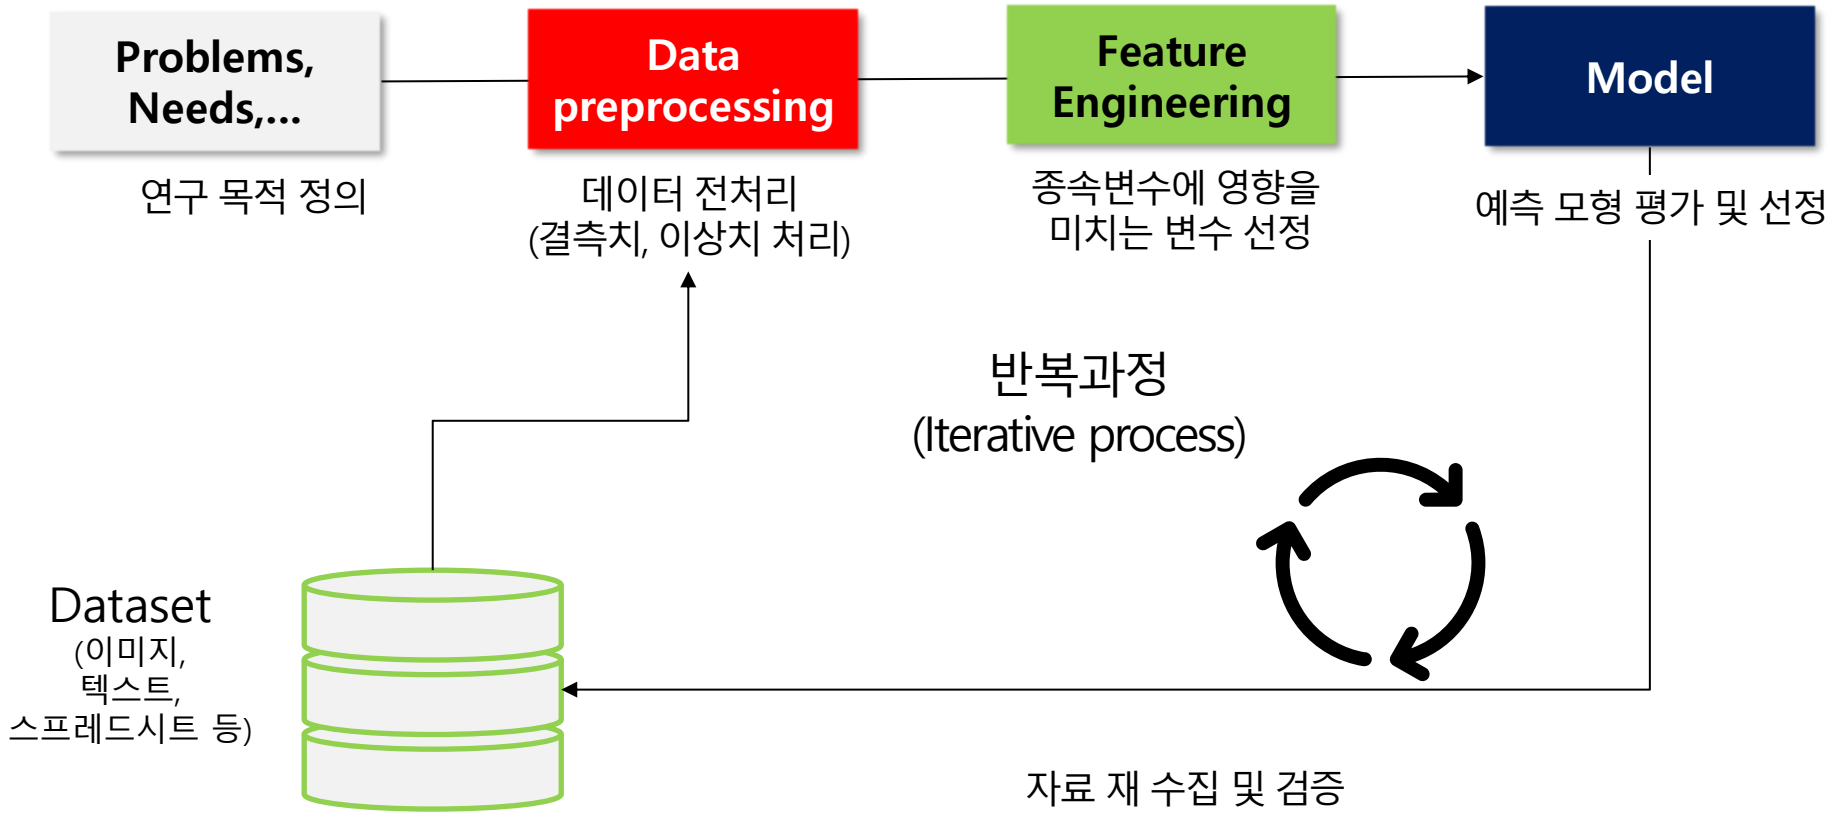
모델 선택 및 평가



학습 목표

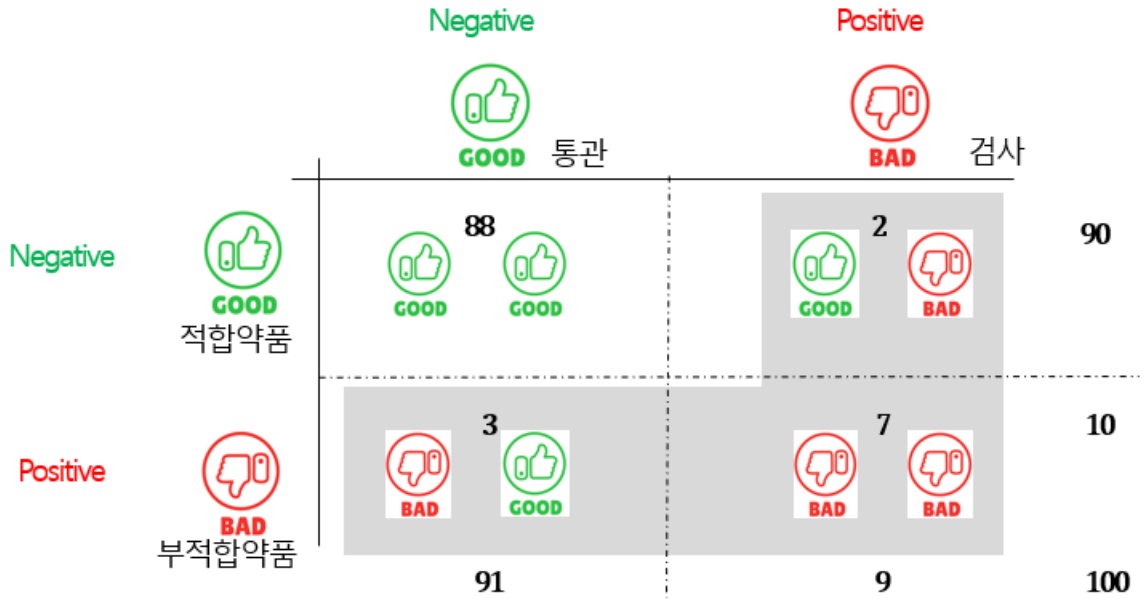
- 분류 모형(Classification Model)를 평가하고 선택하는 정량적 기준(performance metrics)에 대한 이해
  - Accuracy
  - Recall, Precision, f1-score
  - AUROC, PR curve

머신러닝 연구절차


Problems, Needs,...
Data preprocessing
Feature Engineering
Model
연구 목적 정의
데이터 전처리
(결측치, 이상치 처리)
종속변수에 영향을 미치는 변수 선정
예측 모형 평가 및 선정
반복과정
(Iterative process)
Dataset
(이미지, 텍스트, 스프레드시트 등)
자료 재 수집 및 검증

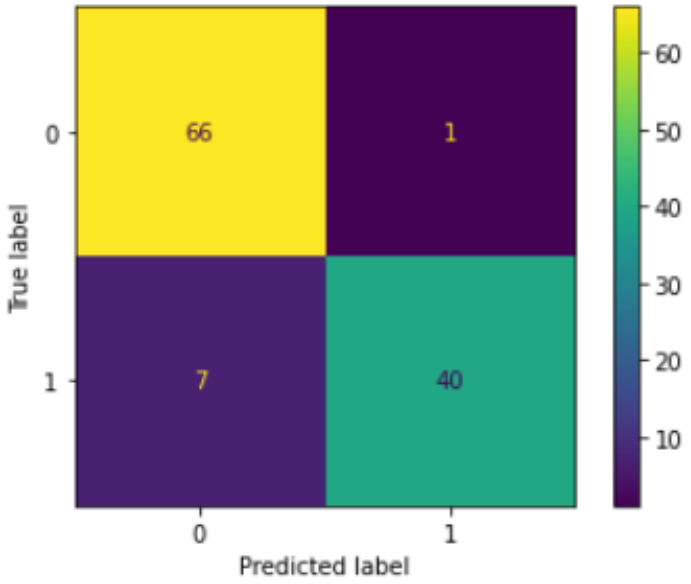
Model evaluation
Recall/Precision

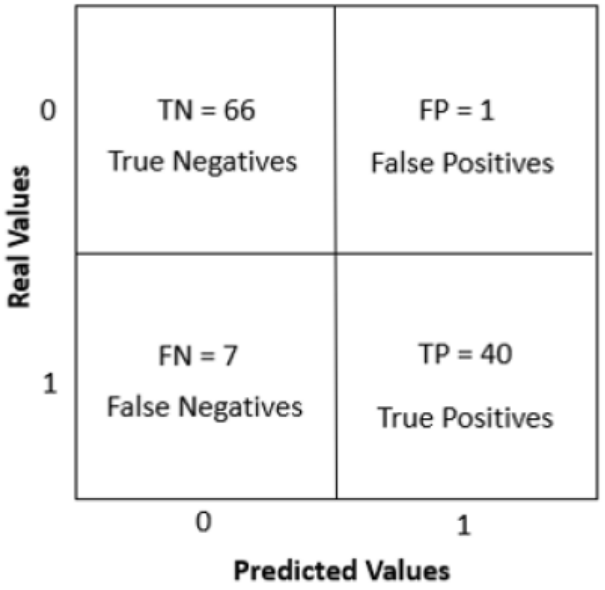
- 정확도(accuracy) : 예측 모형의 전체 정답율 = (88+7)/100
- 정밀도(precesion) : 예측 모형 분류 결과의 정답율 = (7/9), 양성
- 정밀도: 88/91 음성
- 재현율(recall) : 실제 그룹값에서 올바로 골라낸 확률 = (7/10) 양성
- 재현율: 88/90 음성



Model evaluation
Confusion matrix

- 분류모델의 경우 일반적으로 소수범주 유형인 양성(Positive)을 분별하여 예측하는 것이 관심 대상





N = TN + FP = 67

P = FN + TP = 47

정확도 (Accuracy)	**허위양성율 (False Positive Rate, FPR)**	**재현율, 참양성율 (Sensitivity, Recall)**	**정밀도 (Precision)**
(TN + TP) / (N + P)	FN / N	TP / P	TP / (FP + TP)

Model evaluation
Classification report

- 조화평균 (f1-score) : 조화평균, 단순평균(macro avg) : 단순평균
- 가중평균(weighted avg) : 실제 범주의 유형 비중을 고려한 가중평균

	precision	recall	f1-score	support
Negative (0)	0.90	0.99	0.94	67
Positive(1)	0.98	0.85	0.91	47
accuracy			0.93	114
macro avg	0.94	0.92	0.93	114
weighted avg	0.93	0.93	0.93	114

N = TN + FP = 67

P = FN + TP = 47

$$F_{\beta-\text{Score}}$$

$$\frac{(1+\beta^2) * (\text{정밀도 x 재현율})}{(\beta^2 \text{ 정밀도} + \text{재현율})}$$

macro avg recall (단순평균)

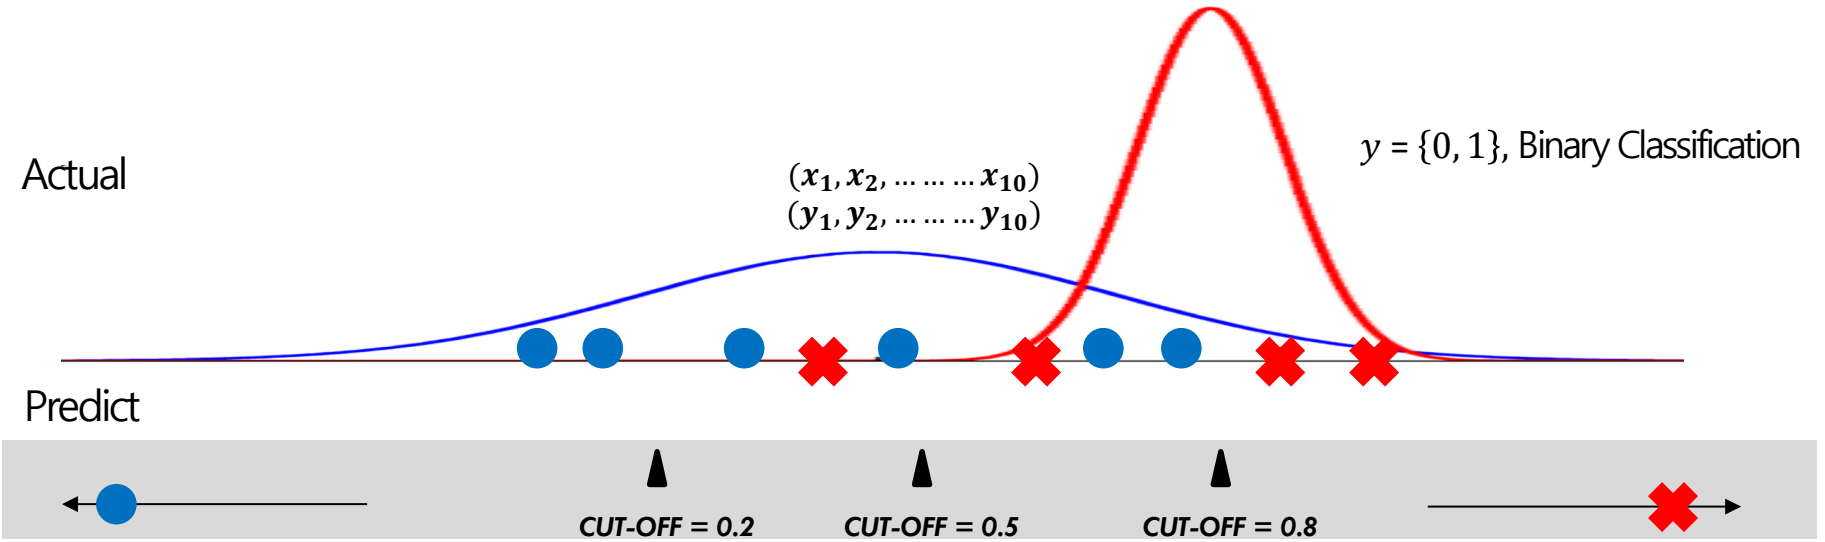
$$\frac{(0.99 + 0.85)}{2}$$

weighted avg recall (가중 평균)

$$\frac{(0.99 * 67 + 0.85 * 47)}{114}$$

수신자운영특성곡선(Receiver Operating Characteristics Curve, ROC)

TPR과 FPR 렊



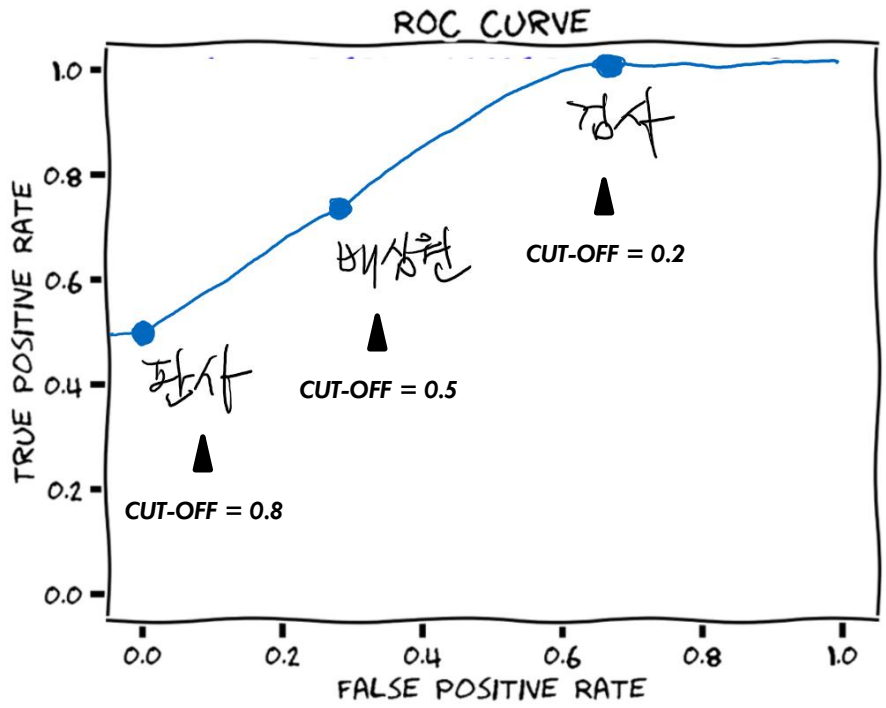
		검사		배심원		판사		
예측		N	P	N	P	N	P	**Support**
실제	N	2	4	4	2	6	0	**6**
	P	0	4	1	3	2	2	**4**
		2	8	5	5	8	2	**10**

Model evaluation
수신자운영특성곡선(Receiver Operating Characteristics Curve, ROC)

- 의사결정임계값에 따른 모델의 성능 지표를 보여주는 그래프

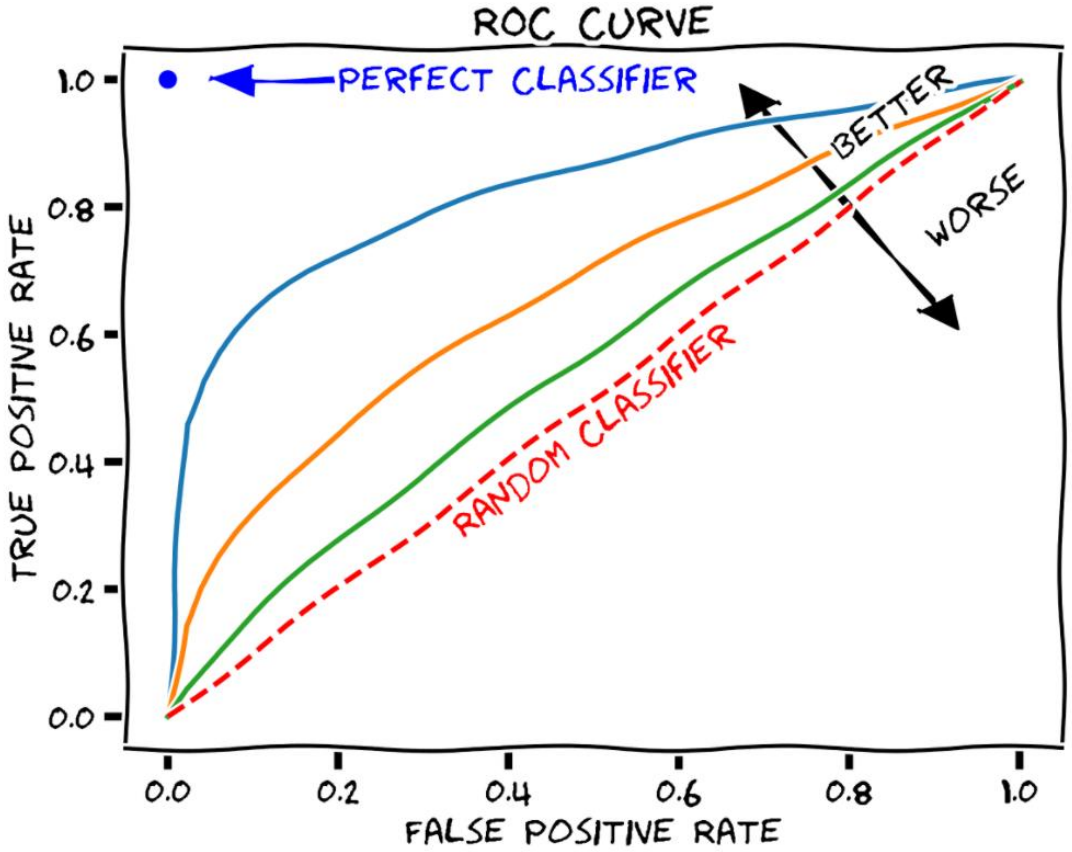
		검사		배심원		판사	
예측		N	P	N	P	N	P
실제	N	2	4	4	2	6	0
	P	0	4	1	3	2	2
		2	8	5	5	8	2

TPR	4/4=1	3/4=0.75	2/2=0.5
FPR	4/6=0.67	2/6=0.33	0/6=0



Model evaluation
수신자운영특성곡선(Receiver Operating Characteristics Curve, ROC)

- confusion matrix에서 생성되며 ROC곡선의 아래 면적(AUROC, Area Under ROC)이 클수록 성능 우수



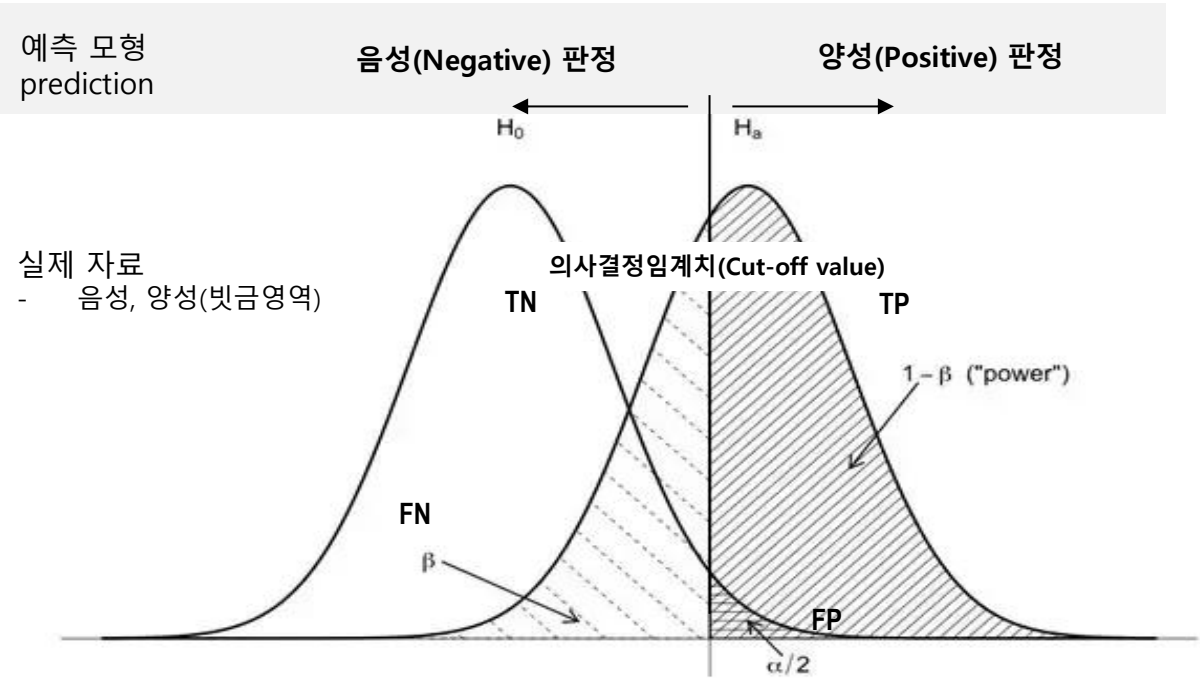
$$AUROC = \int_0^1 TPR(FPR)\, dFPR$$

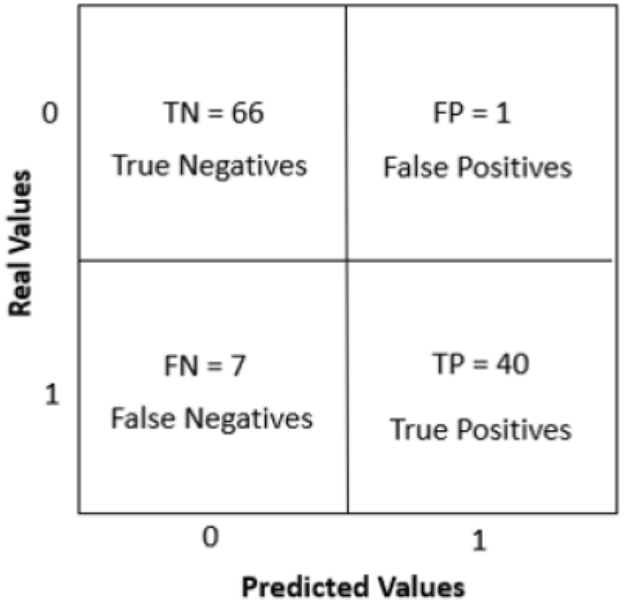
https://slideplayer.com/slide/9562694/

https://en.wikipedia.org/wiki/Receiver_operating_characteristic

Model evaluation
의사결정임계치와 혼동표

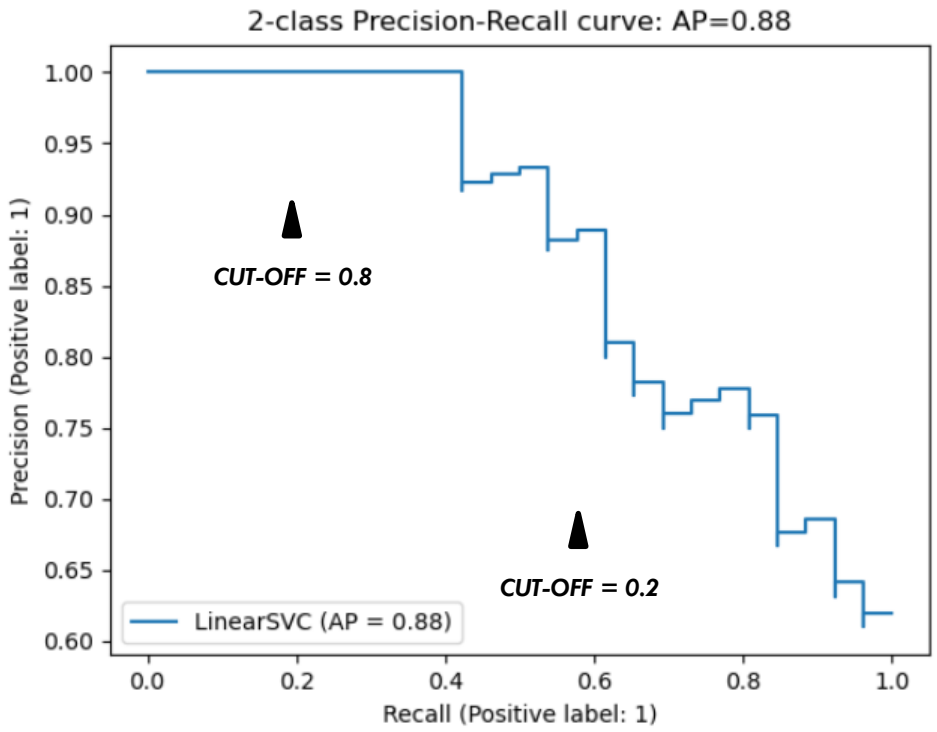
- 카드 사기, 부도업체 적발, 불량 제품 예측 등에는 허위음성(False Negative)를 줄이는 것이 중요
- 양성판정을 엄격하게 하기 위해 Cut-off 값을 증가시키면 참양성 개수(TP)는 감소





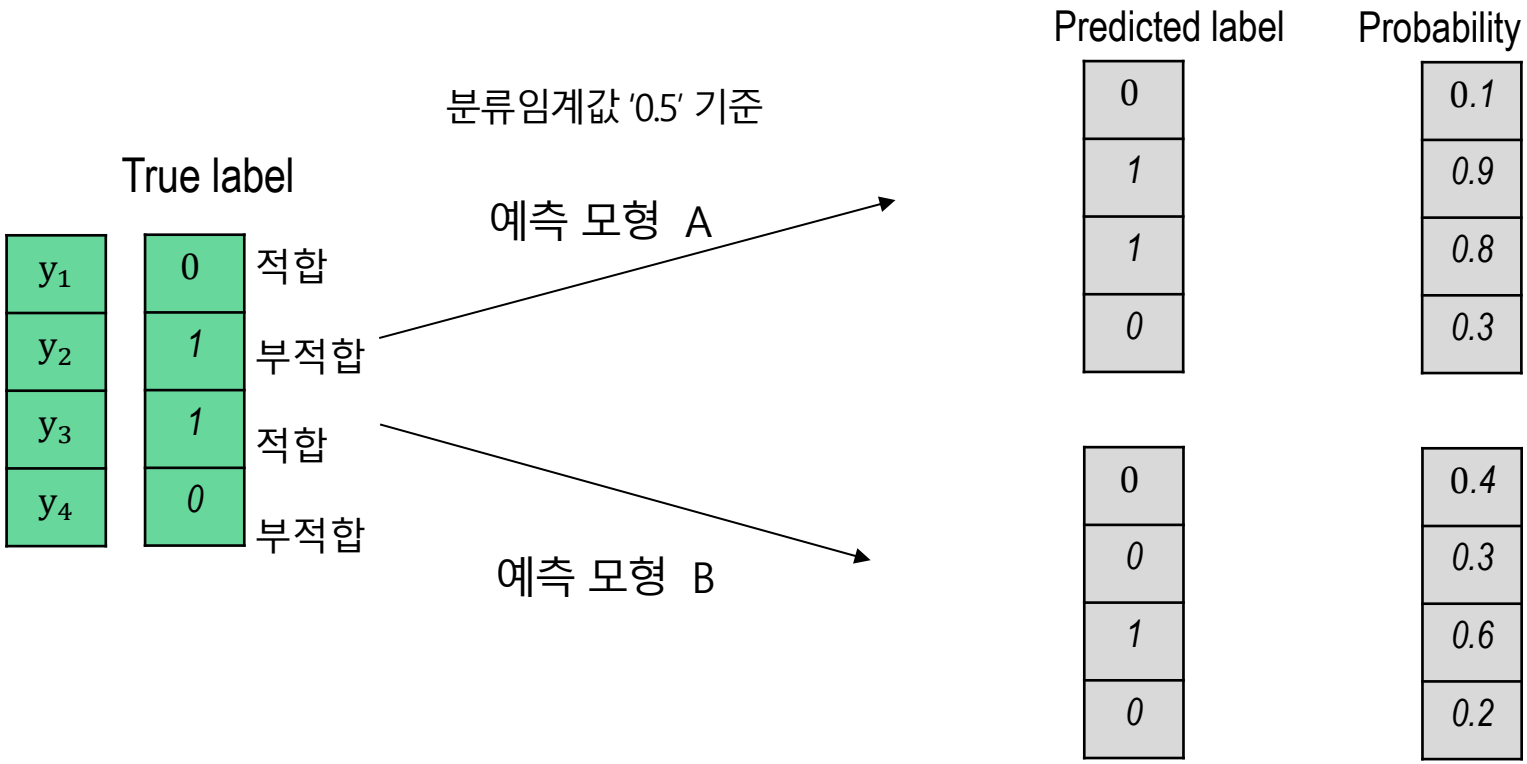
Model evaluation
정밀도-재현율 그래프(Precsion-recall curve, PR Curve)

- 의사결정임계치에 따른 정밀도와 재현율의 반비례 관계를 도식화하여 모델의 성능 지표를 제시
  - 불균형데이터인 경우 AUROC보다는 PR곡선이 더 유용한 성능 지표
  - AP(Average Precision)은 각 의사결정 임계치(threshhold)에서 정밀도의 평균값



https://en.wikipedia.org/wiki/Precision_and_recall

Model evaluation

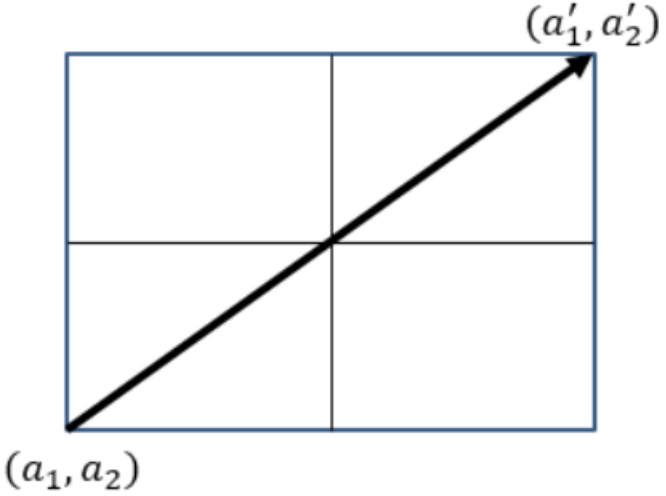


Distance (거리)

Distance

L2 form

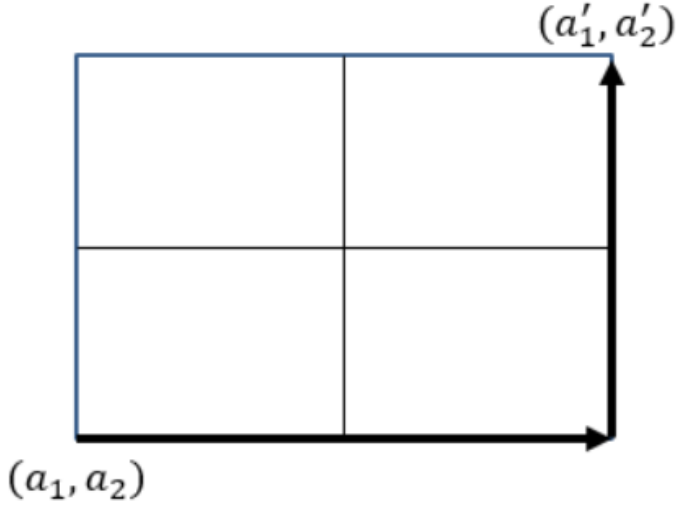
유클리드 거리



$$d = \sqrt{(a_1' - a_1)^2 + (a_2' - a_2)^2}$$

L1 form

맨하튼 거리



$$d = (a_1' - a_1) + (a_2' - a_2)$$

실전문제 - 1

A = (150, 250)	B = (155, 255)



A, B의 유클리디안 거리와 맨하탄 거리를 각각 구하라

실전문제 -2

A = (150, 250, 300)	B = (155, 255, 250)



A, B의 유클리디안 거리와 맨하탄 거리를 각각 구하라